

## 26 | 备库为什么会延迟好几个小时？

2019-01-11 林晓斌



在上一篇文章中，我和你介绍了几种可能导致备库延迟的原因。你会发现，这些场景里，不论是偶发性的查询压力，还是备份，对备库延迟的影响一般是分钟级的，而且在备库恢复正常以后都能够追上来。

但是，如果备库执行日志的速度持续低于主库生成日志的速度，那这个延迟就有可能成了小时级别。而且对于一个压力持续比较高的主库来说，备库很可能永远都追不上主库的节奏。

这就涉及到今天我要给你介绍的话题：备库并行复制能力。

为了便于你理解，我们再一起看一下第24篇文章 [《MySQL是怎么保证主备一致的？》](#) 的主备流程图。

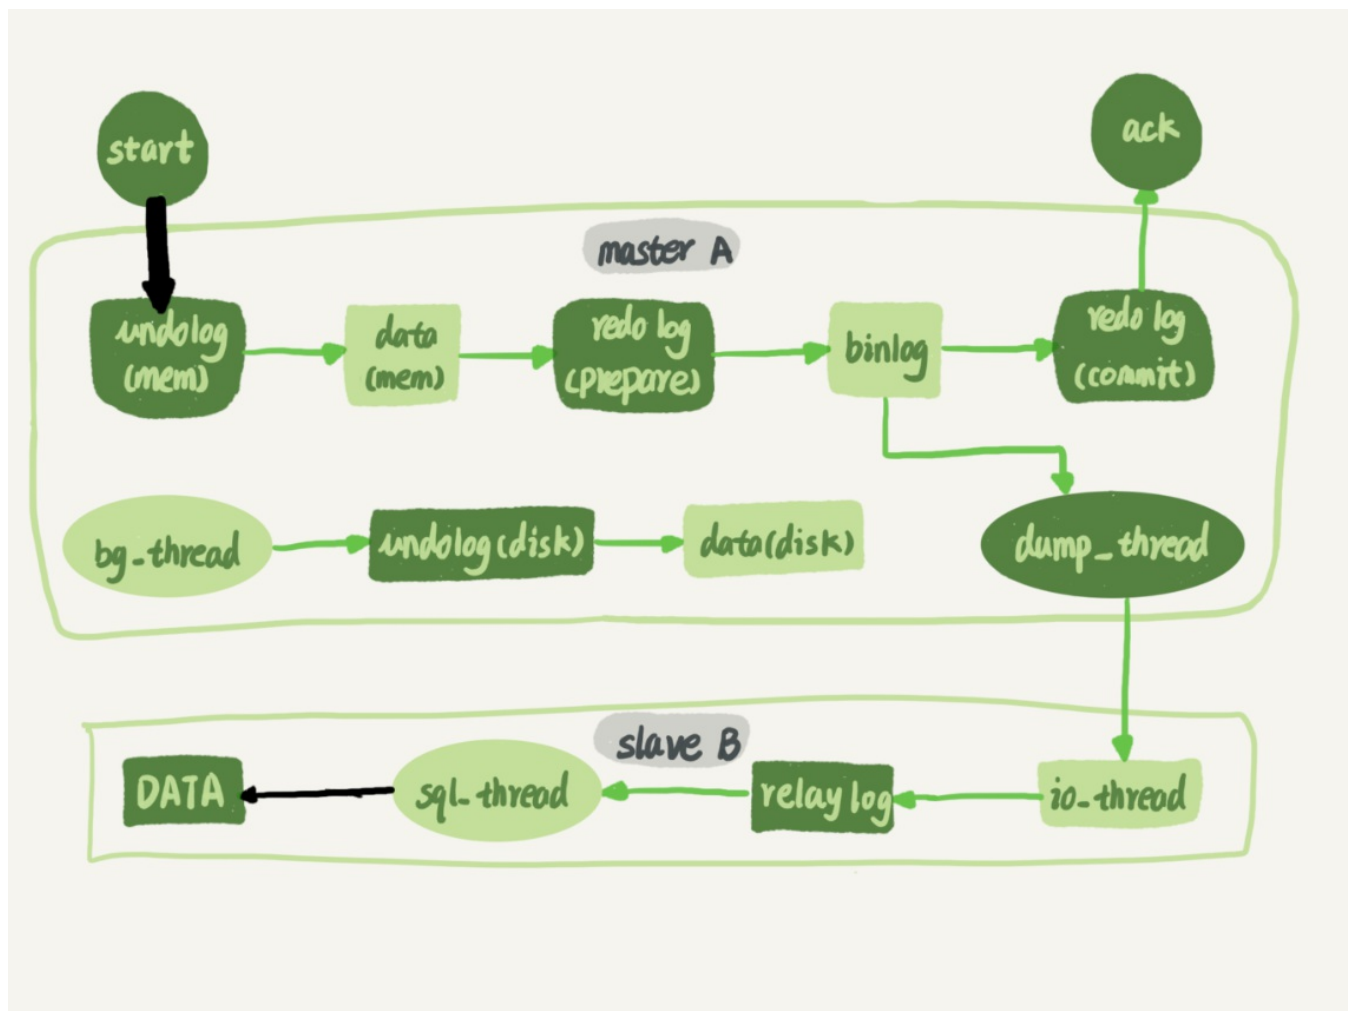


图1 主备流程图

谈到主备的并行复制能力，我们要关注的是图中黑色的两个箭头。一个箭头代表了客户端写入主库，另一箭头代表的是备库上`sql_thread`执行中转日志（`relay log`）。如果用箭头的粗细来代表并行度的话，那么真实情况就如图1所示，第一个箭头要明显粗于第二个箭头。

在主库上，影响并发度的原因就是各种锁了。由于InnoDB引擎支持行锁，除了所有并发事务都在更新同一行（热点行）这种极端场景外，它对业务并发度的支持还是很友好的。所以，你在性能测试的时候会发现，并发压测线程32就比单线程时，总体吞吐量高。

而日志在备库上的执行，就是图中备库上`sql_thread`更新数据（`DATA`）的逻辑。如果是用单线程的话，就会导致备库应用日志不够快，造成主备延迟。

在官方的5.6版本之前，MySQL只支持单线程复制，由此在主库并发高、TPS高时就会出现严重的主备延迟问题。

从单线程复制到最新版本的多线程复制，中间的演化经历了好几个版本。接下来，我就跟你说说MySQL多线程复制的演进过程。

其实说到底，所有的多线程复制机制，都是要把图1中只有一个线程的`sql_thread`，拆成多个线程，也就是都符合下面的这个模型：




图2 多线程模型

图2中，**coordinator**就是原来的**sql\_thread**，不过现在它不再直接更新数据了，只负责读取中转日志和分发事务。真正更新日志的，变成了**worker**线程。而**work**线程的个数，就是由参数**slave\_parallel\_workers**决定的。根据我的经验，把这个值设置为8~16之间最好（32核物理机的情况），毕竟备库还有可能要提供读查询，不能把CPU都吃光了。

接下来，你需要先思考一个问题：事务能不能按照轮询的方式分发给各个**worker**，也就是第一个事务分给**worker\_1**，第二个事务发给**worker\_2**呢？

其实是不行的。因为，事务被分发给**worker**以后，不同的**worker**就独立执行了。但是，由于CPU的调度策略，很可能第二个事务最终比第一个事务先执行。而如果这时候刚好这两个事务更新的是同一行，也就意味着，同一行上的两个事务，在主库和备库上的执行顺序相反，会导致主备不一致的问题。

接下来，请你再设想一下另外一个问题：同一个事务的多个更新语句，能不能分给不同的**worker**来执行呢？

答案是，也不行。举个例子，一个事务更新了表**t1**和表**t2**中的各一行，如果这两条更新语句被分到不同**worker**的话，虽然最终的结果是主备一致的，但如果表**t1**执行完成的瞬间，备库上有一个查询，就会看到这个事务“更新了一半的结果”，破坏了事务逻辑的隔离性。

所以，**coordinator**在分发的时候，需要满足以下这两个基本要求：

1. 不能造成更新覆盖。这就要求更新同一行的两个事务，必须被分发到同一个**worker**中。
2. 同一个事务不能被拆开，必须放到同一个**worker**中。

各个版本的多线程复制，都遵循了这两条基本原则。接下来，我们就看看各个版本的并行复制策略。

## MySQL 5.5版本的并行复制策略

官方MySQL 5.5版本是不支持并行复制的。但是，在2012年的时候，我自己服务的业务出现了严重的主备延迟，原因就是备库只有单线程复制。然后，我就先后写了两个版本的并行策略。

这里，我给你介绍一下这两个版本的并行策略，即按表分发策略和按行分发策略，以帮助你理解MySQL官方版本并行复制策略的迭代。

### 按表分发策略

按表分发事务的基本思路是，如果两个事务更新不同的表，它们就可以并行。因为数据是存储在表里的，所以按表分发，可以保证两个**worker**不会更新同一行。

当然，如果有跨表的事务，还是要把两张表放在一起考虑的。如图3所示，就是按表分发的规则。




图3 按表并行复制模型

可以看到，每个worker线程对应一个hash表，用于保存当前正在这个worker的“执行队列”里的事务所涉及的表。hash表的key是“库名.表名”，value是一个数字，表示队列中有多少个事务修改这个表。

在有事务分配给worker时，事务里面涉及的表会被加到对应的hash表中。worker执行完成后，这个表会被从hash表中去掉。

图3中，hash\_table\_1表示，现在worker\_1的“待执行事务队列”里，有4个事务涉及到db1.t1表，有1个事务涉及到db2.t2表；hash\_table\_2表示，现在worker\_2中有一个事务会更新到表t3的数据。

假设在图中的情况下，coordinator从中转日志中读入一个新事务T，这个事务修改的行涉及到表t1和t3。

现在我们用事务T的分配流程，来看一下分配规则。

1. 由于事务T中涉及修改表t1，而worker\_1队列中有事务在修改表t1，事务T和队列中的某个事务要修改同一个表的数据，这种情况我们说事务T和worker\_1是冲突的。

2. 按照这个逻辑，顺序判断事务T和每个worker队列的冲突关系，会发现事务T跟worker\_2也冲突。
3. 事务T跟多于一个worker冲突，coordinator线程就进入等待。
4. 每个worker继续执行，同时修改hash\_table。假设hash\_table\_2里面涉及到修改表t3的事务先执行完成，就会从hash\_table\_2中把db1.t3这一项去掉。
5. 这样coordinator会发现跟事务T冲突的worker只有worker\_1了，因此就把它分配给worker\_1。
6. coordinator继续读下一个中转日志，继续分配事务。

也就是说，每个事务在分发的时候，跟所有worker的冲突关系包括以下三种情况：

1. 如果跟所有worker都不冲突，coordinator线程就会把这个事务分配给最空闲的worker;
2. 如果跟多于一个worker冲突，coordinator线程就进入等待状态，直到和这个事务存在冲突关系的worker只剩下1个；
3. 如果只跟一个worker冲突，coordinator线程就会把这个事务分配给这个存在冲突关系的worker。

这个按表分发的方案，在多个表负载均匀的场景里应用效果很好。但是，如果碰到热点表，比如所有的更新事务都会涉及到某一个表的时候，所有事务都会被分配到同一个worker中，就变成单线程复制了。

## 按行分发策略

要解决热点表的并行复制问题，就需要一个按行并行复制的方案。按行复制的核心思路是：如果两个事务没有更新相同的行，它们在备库上可以并行执行。显然，这个模式要求binlog格式必须是row。

这时候，我们判断一个事务T和worker是否冲突，用的规则就不是“修改同一个表”，而是“修改同一行”。

按行复制和按表复制的数据结构差不多，也是为每个worker，分配一个hash表。只是要实现按行分发，这时候的key，就必须是“库名+表名+唯一键的值”。

但是，这个“唯一键”只有主键id还是不够的，我们还需要考虑下面这种场景，表t1中除了主键，还有唯一索引a：

```
CREATE TABLE `t1` (  
  `id` int(11) NOT NULL,  
  `a` int(11) DEFAULT NULL,  
  `b` int(11) DEFAULT NULL,  
  PRIMARY KEY (`id`),  
  UNIQUE KEY `a` (`a`)  
) ENGINE=InnoDB;  
  
insert into t1 values(1,1,1),(2,2,2),(3,3,3),(4,4,4),(5,5,5);
```

假设，接下来我们要在主库执行这两个事务：

session A	session B
update t1 set a=6 where id=1;	
	update t1 set a=1 where id=2;

图4 唯一键冲突示例

可以看到，这两个事务要更新的行的主键值不同，但是如果它们被分到不同的worker，就有可能session B的语句先执行。这时候id=1的行的a的值还是1，就会报唯一键冲突。

因此，基于行的策略，事务hash表中还需要考虑唯一键，即key应该是“库名+表名+索引a的名字+a的值”。

比如，在上面这个例子中，我要在表t1上执行update t1 set a=1 where id=2语句，在binlog里面记录了整行的数据修改前各个字段的值，和修改后各个字段的值。

因此，coordinator在解析这个语句的binlog的时候，这个事务的hash表就有三个项：

1. key=hash\_func(db1+t1+“PRIMARY”+2), value=2; 这里value=2是因为修改前后的行id值不变，出现了两次。
2. key=hash\_func(db1+t1+“a”+2), value=1，表示会影响到这个表a=2的行。
3. key=hash\_func(db1+t1+“a”+1), value=1，表示会影响到这个表a=1的行。

可见，相比于按表并行分发策略，按行并行策略在决定线程分发的时候，需要消耗更多的计算资源。你可能也发现了，这两个方案其实都有一些约束条件：

1. 要能够从binlog里面解析出表名、主键值和唯一索引的值。也就是说，主库的binlog格式必

须是row;

2. 表必须有主键;
3. 不能有外键。表上如果有外键，级联更新的行不会记录在binlog中，这样冲突检测就不准确。

但，好在这三条约束规则，本来就是DBA之前要求业务开发人员必须遵守的线上使用规范，所以这两个并行复制策略在应用上也没有碰到什么麻烦。

对比按表分发和按行分发这两个方案的话，按行分发策略的并行度更高。不过，如果是要操作很多行的大事务的话，按行分发的策略有两个问题：

1. 耗费内存。比如一个语句要删除100万行数据，这时候hash表就要记录100万个项。
2. 耗费CPU。解析binlog，然后计算hash值，对于大事务，这个成本还是很高的。

所以，我在实现这个策略的时候会设置一个阈值，单个事务如果超过设置的行数阈值（比如，如果单个事务更新的行数超过10万行），就暂时退化为单线程模式，退化过程的逻辑大概是这样的：

1. coordinator暂时先hold住这个事务；
2. 等待所有worker都执行完成，变成空队列；
3. coordinator直接执行这个事务；
4. 恢复并行模式。

读到这里，你可能会感到奇怪，这两个策略又没有被合到官方，我为什么要介绍这么详细呢？其实，介绍这两个策略的目的是抛砖引玉，方便你理解后面要介绍的社区版本策略。

## MySQL 5.6版本的并行复制策略

官方MySQL5.6版本，支持了并行复制，只是支持的粒度是按库并行。理解了上面介绍的按表分发策略和按行分发策略，你就理解了，用于决定分发策略的hash表里，key就是数据库名。

这个策略的并行效果，取决于压力模型。如果在主库上有多个DB，并且各个DB的压力均衡，使用这个策略的效果会很好。

相比于按表和按行分发，这个策略有两个优势：

1. 构造hash值的时候很快，只需要库名；而且一个实例上DB数也不会很多，不会出现需要构造100万个项这种情况。



2. 不要求binlog的格式。因为statement格式的binlog也可以很容易拿到库名。

但是，如果你的主库上的表都放在同一个DB里面，这个策略就没有效果了；或者如果不同DB的热点不同，比如一个是业务逻辑库，一个是系统配置库，那也起不到并行的效果。

理论上你可以创建不同的DB，把相同热度的表均匀分到这些不同的DB中，强行使用这个策略。不过据我所知，由于需要特地移动数据，这个策略用得并不多。

## MariaDB的并行复制策略

在[第23篇文章](#)中，我给你介绍了redo log组提交(group commit)优化，而MariaDB的并行复制策略利用的就是这个特性：

1. 能够在同一组里提交的事务，一定不会修改同一行；
2. 主库上可以并行执行的事务，备库上也一定是可以并行执行的。

在实现上，MariaDB是这么做的：

1. 在一组里面一起提交的事务，有一个相同的commit\_id，下一组就是commit\_id+1；
2. commit\_id直接写到binlog里面；
3. 传到备库应用的时候，相同commit\_id的事务分发到多个worker执行；
4. 这一组全部执行完成后，coordinator再去取下一批。

当时，这个策略出来的时候是相当惊艳的。因为，之前业界的思路都是在“分析binlog，并拆分到worker”上。而MariaDB的这个策略，目标是“模拟主库的并行模式”。

但是，这个策略有一个问题，它并没有实现“真正的模拟主库并发度”这个目标。在主库上，一组事务在commit的时候，下一组事务是同时处于“执行中”状态的。

如图5所示，假设了三组事务在主库的执行情况，你可以看到在trx1、trx2和trx3提交的时候，trx4、trx5和trx6是在执行的。这样，在第一组事务提交完成的时候，下一组事务很快就会进入commit状态。

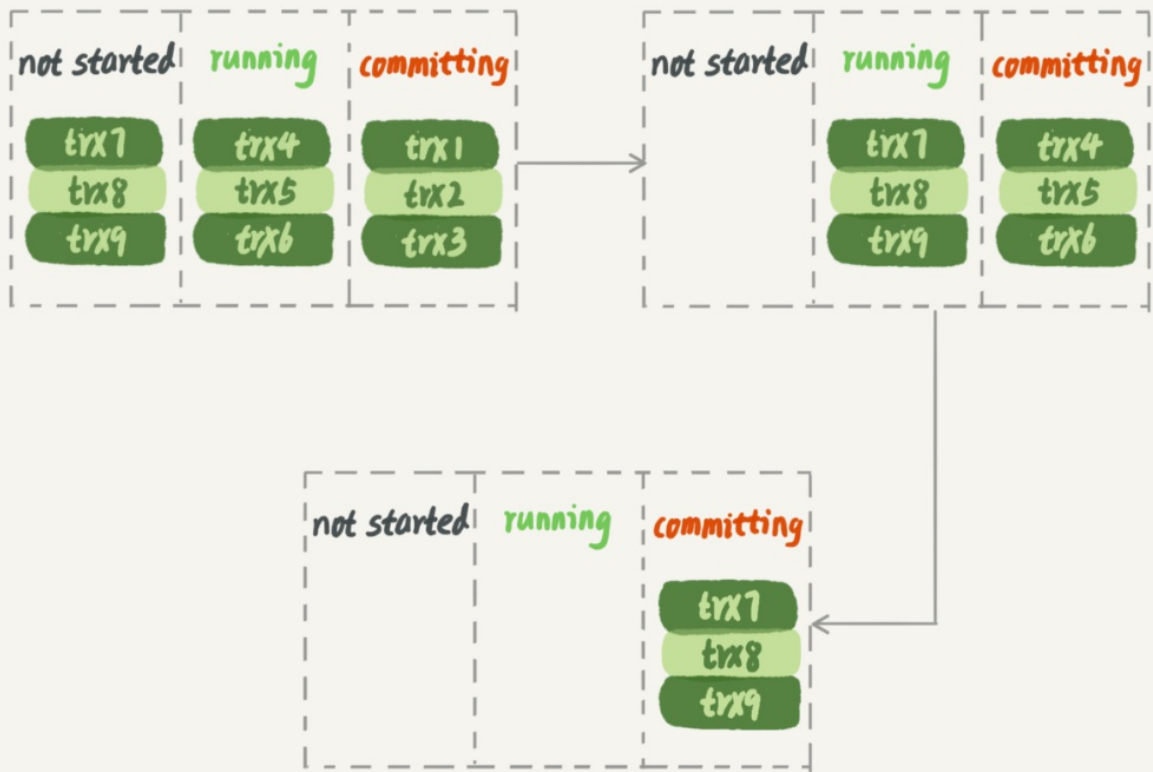


图5 主库并行事务

而按照MariaDB的并行复制策略，备库上的执行效果如图6所示。




图6 MariaDB 并行复制，备库并行效果

可以看到，在备库上执行的时候，要等第一组事务完全执行完成后，第二组事务才能开始执行，这样系统的吞吐量就不够。

另外，这个方案很容易被大事务拖后腿。假设trx2是一个超大事务，那么在备库应用的时候，trx1和trx3执行完成后，就只能等trx2完全执行完成，下一组才能开始执行。这段时间，只有一个worker线程在工作，是对资源的浪费。

不过即使如此，这个策略仍然是一个很漂亮的创新。因为，它对原系统的改造非常少，实现也很优雅。

## MySQL 5.7的并行复制策略

在MariaDB并行复制实现之后，官方的MySQL5.7版本也提供了类似的功能，由参数slave-parallel-type来控制并行复制策略：

1. 配置为DATABASE，表示使用MySQL 5.6版本的按库并行策略；
2. 配置为 LOGICAL\_CLOCK，表示的就是类似MariaDB的策略。不过，MySQL 5.7这个策略，针对并行度做了优化。这个优化的思路也很有趣儿。

你可以先考虑这样一个问题：同时处于“执行状态”的所有事务，是不是可以并行？

答案是，不能。

因为，这里面可能有由于锁冲突而处于锁等待状态的事务。如果这些事务在备库上被分配到不同的worker，就会出现备库跟主库不一致的情况。

而上面提到的MariaDB这个策略的核心，是“所有处于commit”状态的事务可以并行。事务处于commit状态，表示已经通过了锁冲突的检验了。

这时候，你可以再回顾一下两阶段提交，我把前面[第23篇文章](#)中介绍过的两阶段提交过程图贴过来。

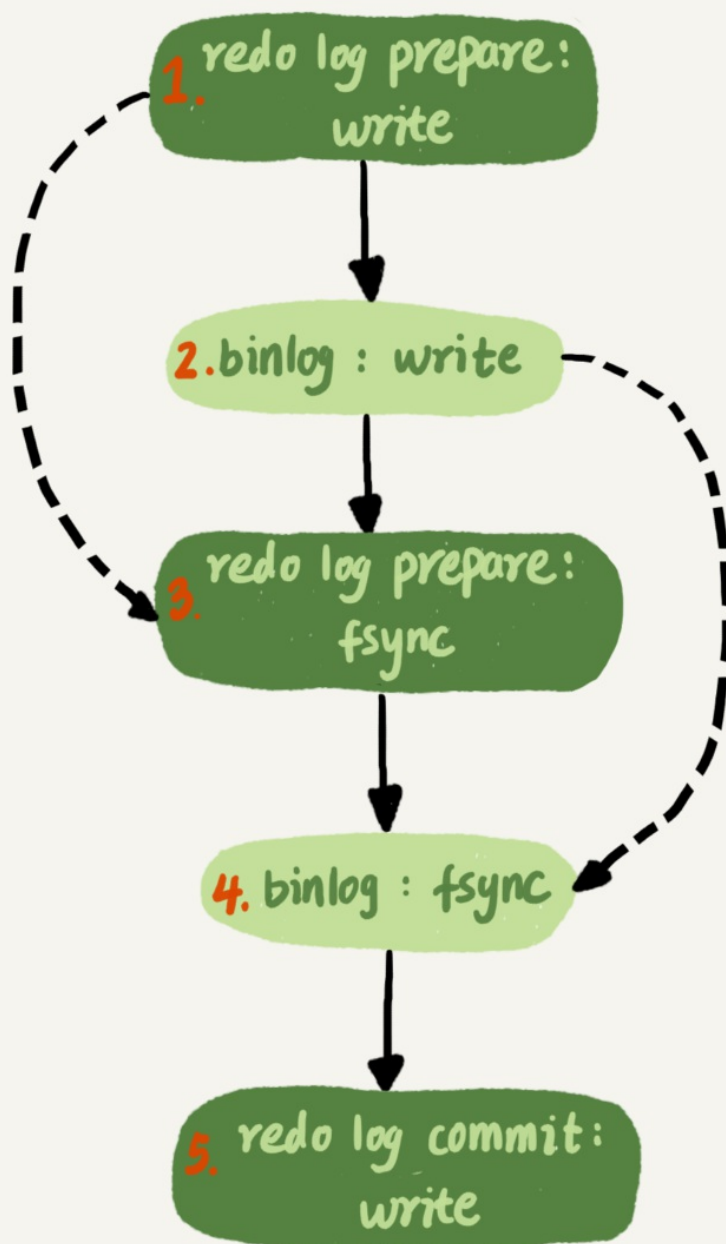


图7 两阶段提交细化过程图

其实，不用等到commit阶段，只要能够到达redo log prepare阶段，就表示事务已经通过锁冲突的检验了。

因此，MySQL 5.7并行复制策略的思想是：

1. 同时处于prepare状态的事务，在备库执行时是可以并行的；
2. 处于prepare状态的事务，与处于commit状态的事务之间，在备库执行时也是可以并行的。

我在第23篇文章，讲binlog的组提交的时候，介绍过两个参数：

1. binlog\_group\_commit\_sync\_delay参数，表示延迟多少微秒后才调用fsync；
2. binlog\_group\_commit\_sync\_no\_delay\_count参数，表示累积多少次以后才调用fsync。

这两个参数是用于故意拉长binlog从write到fsync的时间，以此减少binlog的写盘次数。在MySQL 5.7的并行复制策略里，它们可以用来制造更多的“同时处于prepare阶段的事务”。这样就增加了备库复制的并行度。

也就是说，这两个参数，既可以“故意”让主库提交得慢些，又可以让备库执行得快些。在MySQL 5.7处理备库延迟的时候，可以考虑调整这两个参数值，来达到提升备库复制并发度的目的。

## MySQL 5.7.22的并行复制策略

在2018年4月份发布的MySQL 5.7.22版本里，MySQL增加了一个新的并行复制策略，基于WRITESET的并行复制。

相应地，新增了一个参数binlog-transaction-dependency-tracking，用来控制是否启用这个新策略。这个参数的可选值有以下三种。

1. COMMIT\_ORDER，表示的就是前面介绍的，根据同时进入prepare和commit来判断是否可以并行的策略。
2. WRITESET，表示的是对于事务涉及更新的每一行，计算出这一行的hash值，组成集合writerset。如果两个事务没有操作相同的行，也就是说它们的writerset没有交集，就可以并行。
3. WRITESET\_SESSION，是在WRITESET的基础上多了一个约束，即在主库上同一个线程先后执行的两个事务，在备库执行的时候，要保证相同的先后顺序。

当然为了唯一标识，这个hash值是通过“库名+表名+索引名+值”计算出来的。如果一个表上除了有主键索引外，还有其他唯一索引，那么对于每个唯一索引，insert语句对应的writerset就要多增加一个hash值。

你可能看出来了，这跟我们前面介绍的基于MySQL 5.5版本的按行分发的策略是差不多的。不过，MySQL官方的这个实现还是有很大的优势：

1. **writeset**是在主库生成后直接写入到**binlog**里面的，这样在备库执行的时候，不需要解析**binlog**内容（**event**里的行数据），节省了很多计算量；
2. 不需要把整个事务的**binlog**都扫一遍才能决定分发到哪个**worker**，更省内存；
3. 由于备库的分发策略不依赖于**binlog**内容，所以**binlog**是**statement**格式也是可以的。

因此，**MySQL 5.7.22**的并行复制策略在通用性上还是有保证的。

当然，对于“表上没主键”和“外键约束”的场景，**WRITESET**策略也是没法并行的，也会暂时退化为单线程模型。

## 小结

在今天这篇文章中，我和你介绍了**MySQL**的各种多线程复制策略。

为什么要有多线程复制呢？这是因为单线程复制的能力全面低于多线程复制，对于更新压力较大的主库，备库是可能一直追不上主库的。从现象上看就是，备库上**seconds\_behind\_master**的值越来越大。

在介绍完每个并行复制策略后，我还和你分享了不同策略的优缺点：

- 如果你是**DBA**，就需要根据不同的业务场景，选择不同的策略；
- 如果是你业务开发人员，也希望你能从中获取灵感用到平时的开发工作中。

从这些分析中，你也会发现大事务不仅会影响到主库，也是造成备库复制延迟的主要原因之一。因此，在平时的开发工作中，我建议你尽量减少大事务操作，把大事务拆成小事务。

官方**MySQL 5.7**版本新增的备库并行策略，修改了**binlog**的内容，也就是说**binlog**协议并不是向上兼容的，在主备切换、版本升级的时候需要把这个因素也考虑进去。

最后，我给你留下一个思考题吧。

假设一个**MySQL 5.7.22**版本的主库，单线程插入了很多数据，过了3个小时后，我们要给这个主库搭建一个相同版本的备库。

这时候，你为了更快地让备库追上主库，要开并行复制。在**binlog-transaction-dependency-tracking**参数的**COMMIT\_ORDER**、**WRITESET**和**WRITE\_SESSION**这三个取值中，你会选择哪一个呢？

你选择的原因是什么？如果设置另外两个参数，你认为会出现什么现象呢？

你可以把你的答案和分析写在评论区，我会在下一篇文章跟你讨论这个问题。感谢你的收听，也欢迎你把这篇文章分享给更多的朋友一起阅读。

## 上期问题时间

上期的问题是，什么情况下，备库的主备延迟会表现为一个**45度**的线段？评论区有不少同学的回复都说到了重点：备库的同步在这段时间完全被堵住了。

产生这种现象典型的场景主要包括两种：

- 一种是大事务（包括大表DDL、一个事务操作很多行）；
- 还有一种情况比较隐蔽，就是备库起了一个长事务，比如

```
begin;  
select * from t limit 1;
```

然后就不动了。

这时候主库对表t做了一个加字段操作，即使这个表很小，这个DDL在备库应用的时候也会被堵住，也不能看到这个现象。

评论区还有同学说是不是主库多线程、从库单线程，备库跟不上主库的更新节奏导致的？今天这篇文章，我们刚好讲的是并行复制。所以，你知道了，这种情况会导致主备延迟，但不会表现为这种标准的呈**45度**的直线。

评论区留言点赞板：

| @易翔、@万勇、@老杨同志 等同学的回复都提到了我们上面说的场景；

| @Max 同学提了一个很不错的问题。主备关系里面，备库主动连接，之后的binlog发送是主库主动推送的。之所以这么设计也是为了效率和实时性考虑，毕竟靠备库轮询，会有时间差。



# MySQL 实战 45 讲

从原理到实战，丁奇带你搞懂 MySQL

林晓斌

网名丁奇  
前阿里资深技术专家



新版升级：点击「👤请朋友读」，10位好友免费读，邀请订阅更有**现金**奖励。

## 精选留言



老杨同志

👍 19

尝试回答 慧鑫coming 的问题。

老师图片的步骤有下面5步

1 redo log prepare write

2 binlog write

3 redo log prepare fsync

4 binlog fsync

5 redo log commit write

1)如果更新通一条记录是有锁的，只能一个事务执行，其他事务等待锁。

2)第4步的时候会因为下面两个参数，等其他没有锁冲突的事务，一起刷盘，此时一起执行的事务拥有相同的commit\_id

binlog\_group\_commit\_sync\_delay

binlog\_group\_commit\_sync\_no\_delay\_count

3)执行步骤5后，释放锁，等待锁的事务开始执行。

所以对同一行更新的事务，不可能拥有相同的commit\_id

2019-01-11

作者回复

l, 你比我回复得详细, 顶起

2019-01-11



长杰

6

举个例子, 一个事务更新了表 **t1** 和表 **t2** 中的各一行, 如果这两条更新语句被分到不同 **worker** 的话, 虽然最终的结果是主备一致的, 但如果表 **t1** 执行完成的瞬间, 备库上有一个查询, 就会看到这个事务“更新了一半的结果”, 破坏了事务逻辑的原子性。

老师这块不太明白, 备库有查询会看到更新了一半的结果, **t1**的**worker**执行完了更新会**commit**吗? 如果不**commit**, 备库查询应该看不到吧? 如果**commit**, 就破坏了事物的原子性, 肯定是有问题的。

2019-01-11

作者回复

应该是说, 它迟早要**commit**, 但是两个**worker**是两个线程, 没办法约好“同时提交”, 这样就有可能出现一个先提交一个后提交。

这两个提交之间的时间差, 就能被用户看到“一半事务”, 好问题

2019-01-11



jike

4

老师您好, 开启并行复制后, 事务是按照组来提交的, 从库也是根据**commit\_id**来回放, 如果从库也开启**binlog**的话, 那是不是存在主从的**binlog event**写入顺序不一致的情况呢?

2019-01-15

作者回复

是有可能**binlog event**写入顺序不同的, 好问题

2019-01-15



HuaMax

17

课后题。关键点在于主库单线程, 针对三种不同的策略, **COMMIT\_ORDER**: 没有同时到达**redo log**的**prepare** 状态的事务, 备库退化为单线程; **WRITESET**: 通过对比更新的事务是否存在冲突的行, 可以并发执行; **WRITE\_SESSION**: 在**WRITESET**的基础上增加了线程的约束, 则退化为单线程。综上, 应选择**WRITESET**策略

2019-01-12

作者回复

准确

2019-01-12



每天晒白牙

8

我是做**java**的, 看老师的这个专栏, 确实挺吃力的, 老师专栏的干货太多了, 下面的留言也是相当有水平, 质量都很高, 互动也好, 应该是好多**DBA**吧, 做**java**的我, 看的头大

2019-01-13

作者回复

这几篇偏深, 但确实是大家在使用的时候需要了解的, 到30篇后面的文章会偏应用哈



某、人

👍 6

总结下多线程复制的流程,有不对之处请老师指出:

双1,配置为logical\_clock,假设有三个事务并发执行也已经执行完成(都处于prepare阶段)

1.三个事务把redo log从redo log buffer写到fs page cache中

2.把binlog\_cache flush到binlog文件中,最先进入flush队列的为leader,

其它两个事务为follower.把组员编号以及组的编号写进binlog文件中(三个事务为同一组).

3.三个事务的redo log做fsync,binlog做fsync.

4.dump线程从binlog文件里把binlog event发送给从库

5.I/O线程接收到binlog event,写到relay log中

6.sql thread读取relay log,判断出这三个事务是处于同一个组,

则把这三个事务的event打包发送给三个空闲的worker线程(如果有)并执行。

配置为writeset的多线程复制流程:

1.三个事务把redo log从redo log buffer写到fs page cache中

2.把binlog\_cache flush到binlog文件中,根据表名、主键和唯一键(如果有)生成hash值(writeset),保存到hash表中

判断这三个事务的writeset是否有冲突,如果没有冲突,则视为同组,如果有冲突,则视为不同组.

并把把组员编号以及组的编号写进binlog文件中

(不过一个组的事务个数也不是无限大,由参数binlog\_transaction\_dependency\_history\_size决定组内最多事务数)

3.然后做redo log和binlog的fsync

4.dump线程从binlog文件里把binlog event发送给从库

5.I/O线程接收到binlog event,写到relay log中

6.sql thread读取relay log,如果是同一个组的事务,则把事务分配到不同的worker线程去应用relay log.

不同组的事务,需要等到上一个组的事务全部执行完成,才能分配worker线程应用relay log.

老师我有几个问题想请教下:

1.在备库是单线程下,second\_behind\_master是通过计算T3-T1得到,

在多线程的情况下,是怎么计算出second\_behind\_master的值? 用的是哪一个事务的时间戳?

2.多线程复制下,如果从库宕机了,是不是从库有一个记录表记录那些事务已经应用完成,恢复的时候,只需要恢复未应用的事务.

3.binlog延迟sync的两个参数,是延迟已经flush未sync时间。意思是让事务组占用flush时间更长,之后的事务有更多的时间,从binlog cache进入到flush队列,使得组员变多,起到从库并发的目的因为我理解的是加入到组是在binlog cache flush到binlog文件之前做的,如果此时有事务正在flush,

未sync,则后面的事务必须等待。不知道理解得对不

上面的描述部分，**writeset**的多线程复制流程里面，这段需要修改下：

『2.把binlog\_cache flush到binlog文件中,根据表名、主键和唯一键(如果有)生成hash值(writeset),保存到hash表中

【判断这三个事务的**writeset**是否有冲突,如果没有冲突,则视为同组,如果有冲突,则视为不同组.并把把组员编号以及组的编号写进binlog文件中】』

上面中括号这段要去掉，

判断**writeset**之间是否可以并行这个逻辑，是在备库的**coordinator**线程做的。

----

1. 在多线程并发的时候，**Seconds\_behind\_master**很不准，后面会介绍别的判断方法；

2. 是的,备库有记录，就是**show slave status** 里面的**Relay\_Log\_File** 和 **Relay\_Log\_Pos** 这两个值表示的，好问题

3. ”加入到组是在binlog cache flush到binlog文件之前做的,如果此时有事务正在flush,未sync,则后面的事务必须等待“这句话是对的，但是我没看出这个跟前面提的两个延迟参数作用的关系^

—  
^

2019-01-13



慧鑫coming

👍 5

老师，有个问题，**mariadb**的并行策略，当同一组中有3个事务，它们都对同一行同一字段值进行更改，而它们的**commit\_id**相同，可以在从库并行执行，那么3者的先后顺序是怎么保证不影响该行该字段的最终结果与主库一致？

2019-01-11

作者回复

好问题

不过这个是不可能的哈，对同一行的修改，第一个拿到行锁的事务还没提交前，另外两个会被行锁堵住的，这两个进入不了**commit**状态。所以这三个的**commit\_id**不会相同的

2019-01-11



轻歌赋

👍 3

1, 3会导致备库仍然单线程执行

1是因为没有任何事务时间线是一致的

3是因为单线程执行的事务的先后关系必然不会有重叠的情况，在多线程上面为了保证顺序自然只能一个个过，就成了单线程

2019-03-12



IceGeek17

👍 2

好文，总结对比不同的并行策略，讲的深入浅出，看完豁然开朗。有看源代码的冲动。

2019-01-24

作者回复

看完分享你的心得哈

2019-01-24



观弈道人

👍 2

丁老师你好，问个问题外问题，mysql已经通过gap锁解决了在rr级别下的幻读问题，那么serializable隔离级别目前还有什么用途，一般文章上说的，serializable 主要是为了解决幻读，谢谢回答。

2019-01-12

作者回复

serializable隔离级别确实用得很少（我没有见过在生产上使用的哈）

2019-01-12



MrTrans

👍 1

说实话，这一篇文章我在按表复制和按行复制这一段还是清晰的，但是到了并行复制就不是很清晰了。在MySQL5.7.22新增了binlog-transaction-dependency-tracking，用来控制是否使用并行复制策略，分为commit\_order，writeset和writeset\_session。如果需要备库赶快追上主库，那么就需要更快的并行复制策略，在这里我选择设置为writeset，为什么，因为writeset不需要解析binlog的内容，直接并发执行处理冲突，而commit\_order需要在prepare阶段和commit阶段判断是否可以并行，这样会退化成单线程，再并行复制，writeset\_session还要在writeset的基础上多一个约束，要保证先后顺序，保证过先后顺序就会退化成单线程！

2019-08-30



godtrue

👍 1

原理基本能明白，不过细节基本都在刷新自己的认知，万幸遇到如此牛逼的老师。一个生产的快一个消费的慢，延迟何止几个小时，恐怕此生都赶不上。

2019-08-03



xyl

👍 1

林老师好，问一个最近遇到的问题。有一台5.7版本的MySQL数据库，在开启多线程复制（4）的时候，跑了两天后，然后三个从库同时卡住了，按照MySQL 1864报错，手动调大了三个从库slave\_pending\_jobs\_size\_max的参数之后就恢复了，之前在5.6上没有遇到过这个问题。这里的原理还没想明白，官档上在这里描述的不是很详细，求指导一下。

2019-04-11

作者回复

主要还是从库的apply线程不够快。。

2019-04-20



唯她命

👍 1

老师 我觉得图6好像有问题啊，在图5中,主库trx1,trx2,trx3是同一组里面的事务，他们拥有相同的commit\_id，他们到备库里面需要被分到不同的worker里面去执行，但是图6里面，trx1,trx2,trx3还依然在一组里面？这是不是矛盾了？

2019-04-08

作者回复

这里没有矛盾哈。图6中，画在同一组的，就表示可以并行执行。也就是说，图6中，123是并行执行，然后456并行，然后789并行

2019-04-30



lingw

1

学习完这篇写下自己的理解，老师有空帮忙看下哦，备库一般会延迟分钟级别，比如主库压力比较大的时候，备库有可能会延迟小时级别，为此mysql官方提供了多种多线程复制策略

1、5.6基于库的多线程复制策略，使用hash数据库名作为key，value为多少个事务修改此数据库，使用hash来分配多线程，如果一个新事务加入进来，如果有冲突的hash，分配给此线程，如果没有冲突分配给空闲的线程，感觉实现的思路使用队列+线程池，如果线程池中没空闲的线程，就在队列中增加事务，如果队列满，分发器阻塞，不解析binlog，分发器是生产者，线程池是消费者，基于库的多线程复制有如下优点①构造hash值的时候很快，只需要库名；线程的hash项也很少②binlog不需要强制指定row，statement也可以拿到库名。缺点：①如果只有一个库单线程复制，可以将其热点表分布到多个库中（不推荐使用），如果多个库的热点程度不同也会使其单线程复制。

2、基于表的多线程复制（非官方，老师实现），hash数据库名+表名作为key，value为多少个事务修改此数据表，同一个事务的多张表，在同一个线程进行处理，防止违反原子性，优点对同一个库多个热点表可以同时复制，多表负载效果很好，如果碰到热点表，比如所有的更新事务都会涉及到某一个表的时候，会使用单线程复制。

3、基于行的多线程复制，key必须是“库名 + 表名 + 唯一键的值”也需考虑唯一主键，防止唯一主键冲突（cpu的多线程调度，顺序不固定），value为修改前后key的次数，约束①表必须有主键②不能有外键③binlog格式row（表复制也一样）缺点：①大事务耗cpu②hash项多。优化可以设置阈值，如果事务修改的行大于特定值，使用单线程复制（老师自己实现）。mysql官网基于行的多线程复制，表示的是对于事务涉及更新的每一行，计算出每一行的hash保存在write set中，优点，①是有mysql主库写入binlog中，不需要解析binlog内容（event里的行数据），节省计算量②binlog格式没要求，可以使用statement③无需扫描整个事务的binlog省内存，mysql 5.7.22的多线程复制实现方式。

4、mysql 5.7的多线程复制实现方式，借助于处于redo prepare到commit状态下的事务可以并行，因为执行器引擎拿数据时，事务如果锁冲突会阻塞，无法到写redo log这一步，可以使用binlog故意延迟fsync，防止频繁写磁盘操作，不会丢失数据（redo prepare+完整的binlog事务才能提交，否则回滚），使其在备库多线程复制，主备延迟低，但是这样有一点不好，语句的响应时间变长，感觉mysql官网故意延迟redo的fsync，在binlog write的时候（因为事务的binlog要写完整，时间较长），使其能批量提交，减少iops，感觉很巧妙

2019-03-10

作者回复

1

2019-03-23



胡楚坚

1

老师，关于留言板中置顶留言长杰的问题：一个事务更新了两张表的数据，然后两个更新语句分给了两个worker。这问题我有点不明白，因为看完专栏我的认知是一个事务只会给一个worker执行，这样就不会有先后commit问题。请问老师是我看漏了什么吗？这种情况应该会出现哪种策略？

2019-02-18

作者回复

一个事务只能发给一个worker的，



长杰评论的那个问题，讨论的是如果分成两个事务，然后约定一起提交，这个是做不到的（或者说实现起来很复杂）

2019-02-18



J!

1

同时处于 **prepare** 状态的事务，在备库执行时是可以并行复制的，是这个**prepare** 就可以生成了改组的**committed id**吗

极客时间版权所有: <https://time.geekbang.org/column/article/77083>

2019-02-01

作者回复

进入**prepare** 的时候就给这个事务分配 **commitid**，这个**commitid**就是当前系统最大的一个**commitid**

2019-02-02



J!

1

5.7 版本的基于组提交的并行复制。**last\_commitid** 是在什么时候生成的？

2019-02-01

作者回复

事务提交的时候

2019-02-02



alias cd=rm -rf

1

老师您好：

思考题答案的猜测：建议采用 **WRITESET**。

**WRITESET\_SESSION**：因为主库是单线程插入，如果采用**WRITESET\_SESSION**，那么会退化成单线程主从复制。

**COMMIT\_ORDER**：因为是追历史数据，所以会退化成单线程。

2019-02-01

作者回复

对的，

2019-02-02



时隐时现

1

Furthermore, given that changes are propagated and applied in row-based format, this means that they are received in an optimized and compact format, and likely reducing the number of IO operations required when compared to the originating member.

这个是官档上对MGR的一段解读，我的疑问是：

为何row-base replication在从库回放时会节省大量IO？

候选答案：

1、省去了sql解析，直接调用do\_command

2、？？

可是row复制有其他可能存在的劣势，比如单个大dml会被解析成多个dml\_event进行重放，万一该表没有主键或唯一索引，只能采用二级索引或者全表扫描(开启hash\_scan也可以)，所以，官档上直接说会减少大量IO是不是有点太武断了

2019-01-31

作者回复

这个描述应该是主要考虑在有主键的时候，可以通过row里面的信息取出主键直接定位记录。

你说的这些其实劣势确实也是存在的

2019-01-31