33 | 我查这么多数据,会不会把数据库内存打爆?

2019-01-28 林晓斌



我经常会被问到这样一个问题:我的主机内存只有100G,现在要对一个200G的大表做全表扫描,会不会把数据库主机的内存用光了?

这个问题确实值得担心,被系统**OOM**(**out of memory**)可不是闹着玩的。但是,反过来想想,逻辑备份的时候,可不就是做整库扫描吗?如果这样就会把内存吃光,逻辑备份不是早就挂了? 所以说,对大表做全表扫描,看来应该是没问题的。但是,这个流程到底是怎么样的呢?

全表扫描对server层的影响

假设,我们现在要对一个**200G**的**InnoDB**表**db1**. **t**,执行一个全表扫描。当然,你要把扫描结果保存在客户端,会使用类似这样的命令:

mysql -h\$host -P\$port -u\$user -p\$pwd -e "select * from db1.t" > \$target_file

你已经知道了,InnoDB的数据是保存在主键索引上的,所以全表扫描实际上是直接扫描表t的主键索引。这条查询语句由于没有其他的判断条件,所以查到的每一行都可以直接放到结果集里面,然后返回给客户端。

那么,这个"结果集"存在哪里呢?

实际上,服务端并不需要保存一个完整的结果集。取数据和发数据的流程是这样的:

- 1. 获取一行,写到net_buffer中。这块内存的大小是由参数net_buffer_length定义的,默认是 16k。
- 2. 重复获取行,直到net buffer写满,调用网络接口发出去。
- 3. 如果发送成功,就清空net buffer,然后继续取下一行,并写入net buffer。
- 4. 如果发送函数返回EAGAIN或WSAEWOULDBLOCK,就表示本地网络栈(socket send buffer)写满了,进入等待。直到网络栈重新可写,再继续发送。

这个过程对应的流程图如下所示。

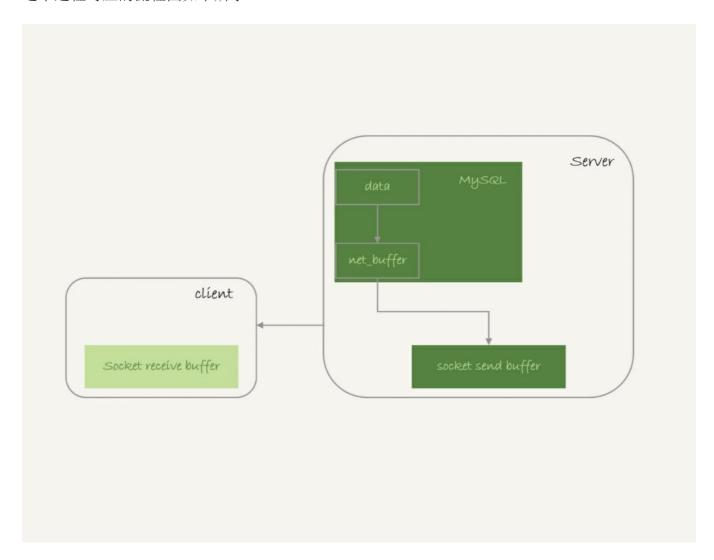


图1查询结果发送流程

从这个流程中, 你可以看到:

- 1. 一个查询在发送过程中,占用的**MySQL**内部的内存最大就是**net_buffer_length**这么大,并不会达到**200G**:
- 2. socket send buffer 也不可能达到200G (默认定义/proc/sys/net/core/wmem_default),如

果socket send buffer被写满,就会暂停读数据的流程。

也就是说,**MySQL是"边读边发的"**,这个概念很重要。这就意味着,如果客户端接收得慢,会导致**MySQL**服务端由于结果发不出去,这个事务的执行时间变长。

比如下面这个状态,就是我故意让客户端不去读**socket receive buffer**中的内容,然后在服务端**show processlist**看到的结果。

mysql> si	now processlist;					
Id Us	ser Host	db	Command	Time	State	Info
4 ro	oot localhost:61696 oot localhost:61772	test test	Query Query		starting Sending to client	

图2服务端发送阻塞

如果你看到State的值一直处于"Sending to client",就表示服务器端的网络栈写满了。

我在上一篇文章中曾提到,如果客户端使用-quick参数,会使用mysql_use_result方法。这个方法是读一行处理一行。你可以想象一下,假设有一个业务的逻辑比较复杂,每读一行数据以后要处理的逻辑如果很慢,就会导致客户端要过很久才会去取下一行数据,可能就会出现如图2所示的这种情况。

因此,对于正常的线上业务来说,如果一个查询的返回结果不会很多的话,我都建议你使用mysql_store_result这个接口,直接把查询结果保存到本地内存。

当然前提是查询返回结果不多。在<u>第30篇文章</u>评论区,有同学说到自己因为执行了一个大查询导致客户端占用内存近**20G**,这种情况下就需要改用**mysql_use_result**接口了。

另一方面,如果你在自己负责维护的MySQL里看到很多个线程都处于"Sending to client"这个状态,就意味着你要让业务开发同学优化查询结果,并评估这么多的返回结果是否合理。

而如果要快速减少处于这个状态的线程的话,将**net_buffer_length**参数设置为一个更大的值是一个可选方案。

与"Sending to client"长相很类似的一个状态是"Sending data",这是一个经常被误会的问题。有同学问我说,在自己维护的实例上看到很多查询语句的状态是"Sending data",但查看网络也没什么问题啊,为什么Sending data要这么久?

实际上,一个查询语句的状态变化是这样的(注意:这里,我略去了其他无关的状态):

- MySQL查询语句进入执行阶段后,首先把状态设置成"Sending data";
- 然后,发送执行结果的列相关的信息(meta data)给客户端;
- 再继续执行语句的流程;

• 执行完成后,把状态设置成空字符串。

也就是说,"Sending data"并不一定是指"正在发送数据",而可能是处于执行器过程中的任意阶段。比如,你可以构造一个锁等待的场景,就能看到Sending data状态。

session A	session B
beign; select * from t where id=1 for update;	
	select * from t lock in share mode; (blocked)

图3读全表被锁

mysql> show	processlist;					
Id Use	Host	db	Command	Time	State	Info
5 root	localhost:15392 localhost:15406 localhost:16412	test	Query		Sending data	NULL select * from t lock in share mode show processlist

图 4 Sending data状态

可以看到,session B明显是在等锁,状态显示为Sending data。

也就是说,仅当一个线程处于"等待客户端接收结果"的状态,才会显示"Sending to client";而如果显示成"Sending data",它的意思只是"正在执行"。

现在你知道了,查询的结果是分段发给客户端的,因此扫描全表,查询返回大量的数据,并不会把内存打爆。

在**server**层的处理逻辑我们都清楚了,在**InnoDB**引擎里面又是怎么处理的呢? 扫描全表会不会对引擎系统造成影响呢?

全表扫描对InnoDB的影响

在<u>第2</u>和<u>第15篇</u>文章中,我介绍WAL机制的时候,和你分析了InnoDB内存的一个作用,是保存更新的结果,再配合redo log,就避免了随机写盘。

内存的数据页是在Buffer Pool (BP)中管理的,在WAL里Buffer Pool 起到了加速更新的作用。而实际上,Buffer Pool 还有一个更重要的作用,就是加速查询。

在第**2**篇文章的评论区有同学问道,由于有**WAL**机制,当事务提交的时候,磁盘上的数据页是旧的,那如果这时候马上有一个查询要来读这个数据页,是不是要马上把**redo log**应用到数据页呢?

答案是不需要。因为这时候内存数据页的结果是最新的,直接读内存页就可以了。你看,这时候查询根本不需要读磁盘,直接从内存拿结果,速度是很快的。所以说,**Buffer Pool**还有加速查询的作用。

而Buffer Pool对查询的加速效果,依赖于一个重要的指标,即:内存命中率。

你可以在**show engine innodb status**结果中,查看一个系统当前的**BP**命中率。一般情况下,一个稳定服务的线上系统,要保证响应时间符合要求的话,内存命中率要在**99%**以上。

执行show engine innodb status ,可以看到"Buffer pool hit rate"字样,显示的就是当前的命中率。比如图5这个命中率,就是99.0%。

Buffer pool hit rate 990 / 1000

图5 show engine innodb status显示内存命中率

如果所有查询需要的数据页都能够直接从内存得到,那是最好的,对应的命中率就是**100%**。 但,这在实际生产上是很难做到的。

InnoDB Buffer Pool的大小是由参数 innodb_buffer_pool_size确定的,一般建议设置成可用物理内存的60%~80%。

在大约十年前,单机的数据量是上百个**G**,而物理内存是几个**G**;现在虽然很多服务器都能有**128G**甚至更高的内存,但是单机的数据量却达到了**T**级别。

所以,innodb_buffer_pool_size小于磁盘的数据量是很常见的。如果一个 Buffer Pool满了,而又要从磁盘读入一个数据页,那肯定是要淘汰一个旧数据页的。

InnoDB内存管理用的是最近最少使用 (Least Recently Used, LRU)算法,这个算法的核心就是 淘汰最久未使用的数据。

下图是一个LRU算法的基本模型。

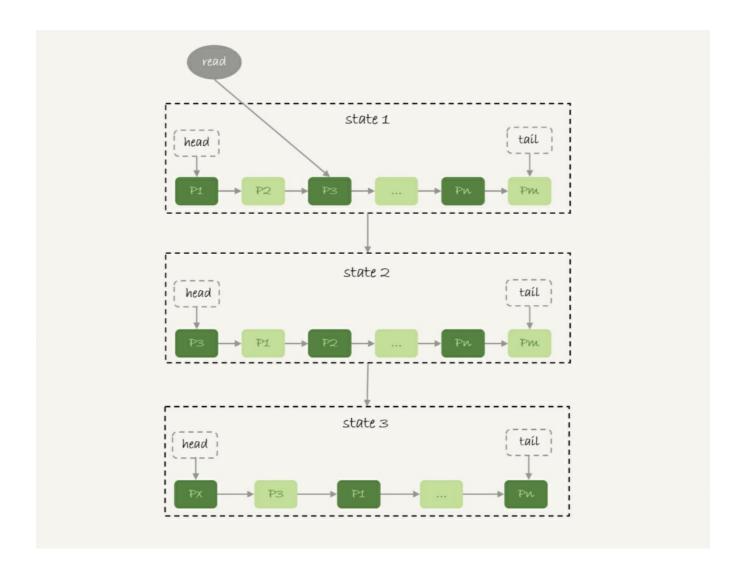


图6基本LRU算法

InnoDB管理Buffer Pool的LRU算法,是用链表来实现的。

- 1. 在图6的状态1里,链表头部是P1,表示P1是最近刚刚被访问过的数据页;假设内存里只能放下这么多数据页;
- 2. 这时候有一个读请求访问P3, 因此变成状态2, P3被移到最前面;
- 3. 状态3表示,这次访问的数据页是不存在于链表中的,所以需要在Buffer Pool中新申请一个数据页Px,加到链表头部。但是由于内存已经满了,不能申请新的内存。于是,会清空链表末尾Pm这个数据页的内存,存入Px的内容,然后放到链表头部。
- 4. 从效果上看,就是最久没有被访问的数据页Pm,被淘汰了。

这个算法乍一看上去没什么问题,但是如果考虑到要做一个全表扫描,会不会有问题呢?

假设按照这个算法,我们要扫描一个**200G**的表,而这个表是一个历史数据表,平时没有业务访问它。

那么,按照这个算法扫描的话,就会把当前的Buffer Pool里的数据全部淘汰掉,存入扫描过程中

访问到的数据页的内容。也就是说Buffer Pool里面主要放的是这个历史数据表的数据。

对于一个正在做业务服务的库,这可不妙。你会看到,Buffer Pool的内存命中率急剧下降,磁盘压力增加,SQL语句响应变慢。

所以,InnoDB不能直接使用这个LRU算法。实际上,InnoDB对LRU算法做了改进。

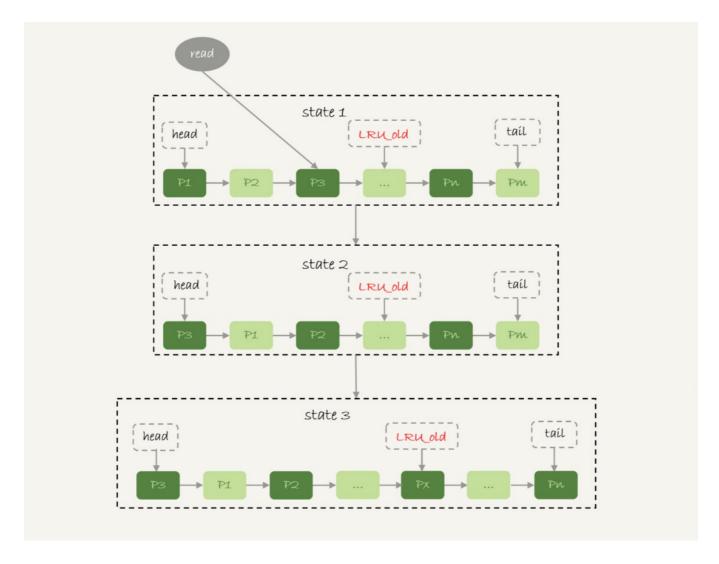


图 7 改进的LRU算法

在InnoDB实现上,按照5:3的比例把整个LRU链表分成了young区域和old区域。图中LRU_old指向的就是old区域的第一个位置,是整个链表的5/8处。也就是说,靠近链表头部的5/8是young区域,靠近链表尾部的3/8是old区域。

改进后的LRU算法执行流程变成了下面这样。

- 1. 图**7**中状态**1**,要访问数据页**P3**,由于**P3**在young区域,因此和优化前的**LRU**算法一样,将 其移到链表头部,变成状态**2**。
- 2. 之后要访问一个新的不存在于当前链表的数据页,这时候依然是淘汰掉数据页Pm,但是新插入的数据页Px,是放在LRU old处。

- 3. 处于old区域的数据页,每次被访问的时候都要做下面这个判断:
 - 。 若这个数据页在LRU链表中存在的时间超过了1秒, 就把它移动到链表头部:
 - 。如果这个数据页在LRU链表中存在的时间短于1秒,位置保持不变。1秒这个时间,是由参数innodb_old_blocks_time控制的。其默认值是1000,单位毫秒。

这个策略,就是为了处理类似全表扫描的操作量身定制的。还是以刚刚的扫描**200G**的历史数据表为例,我们看看改进后的**LRU**算法的操作逻辑:

- 1. 扫描过程中,需要新插入的数据页,都被放到**old**区域;
- 2. 一个数据页里面有多条记录,这个数据页会被多次访问到,但由于是顺序扫描,这个数据页第一次被访问和最后一次被访问的时间间隔不会超过**1**秒,因此还是会被保留在**old**区域:
- 3. 再继续扫描后续的数据,之前的这个数据页之后也不会再被访问到,于是始终没有机会移到链表头部(也就是young区域),很快就会被淘汰出去。

可以看到,这个策略最大的收益,就是在扫描这个大表的过程中,虽然也用到了Buffer Pool,但是对young区域完全没有影响,从而保证了Buffer Pool响应正常业务的查询命中率。

小结

今天,我用"大查询会不会把内存用光"这个问题,和你介绍了MySQL的查询结果,发送给客户端的过程。

由于**MySQL**采用的是边算边发的逻辑,因此对于数据量很大的查询结果来说,不会在**server**端保存完整的结果集。所以,如果客户端读结果不及时,会堵住**MySQL**的查询过程,但是不会把内存打爆。

而对于InnoDB引擎内部,由于有淘汰策略,大查询也不会导致内存暴涨。并且,由于InnoDB对 LRU算法做了改进,冷数据的全表扫描,对Buffer Pool的影响也能做到可控。

当然,我们前面文章有说过,全表扫描还是比较耗费**IO**资源的,所以业务高峰期还是不能直接在线上主库执行全表扫描的。

最后, 我给你留一个思考题吧。

我在文章中说到,如果由于客户端压力太大,迟迟不能接收结果,会导致**MySQL**无法发送结果而影响语句执行。但,这还不是最糟糕的情况。

你可以设想出由于客户端的性能问题,对数据库影响更严重的例子吗?或者你是否经历过这样的场景?你又是怎么优化的?

你可以把你的经验和分析写在留言区,我会在下一篇文章的末尾和你讨论这个问题。感谢你的收

听,也欢迎你把这篇文章分享给更多的朋友一起阅读。

上期问题时间

上期的问题是,如果一个事务被kill之后,持续处于回滚状态,从恢复速度的角度看,你是应该重启等它执行结束,还是应该强行重启整个MySQL进程。

因为重启之后该做的回滚动作还是不能少的,所以从恢复速度的角度来说,应该让它自己结束。

当然,如果这个语句可能会占用别的锁,或者由于占用**IO**资源过多,从而影响到了别的语句执行的话,就需要先做主备切换,切到新主库提供服务。

切换之后别的线程都断开了连接,自动停止执行。接下来还是等它自己执行完成。这个操作属于 我们在文章中说到的,减少系统压力,加速终止逻辑。

评论区留言点赞板:

@HuaMax 的回答中提到了对其他线程的影响;

@夹心面包 @Ryoma @曾剑 同学提到了重启后依然继续做回滚操作的逻辑。



新版升级:点击「 💫 请朋友读 」,10位好友免费读,邀请订阅更有现金奖励。

凸 12

如果你看到 State 的值一直处于"Sending to client",就表示服务器端的网络栈写满了。如何处理?

- 1)使用 mysql store result 这个接口,直接把查询结果保存到本地内存。
- 2)优化查询结果,并评估这么多的返回结果是否合理。
- **3)**而如果要快速减少处于这个状态的线程的话,将 **net_buffer_length** 参数设置为一个更大的值是一个可选方案。

对于第3)方案不是很懂,"Sending to client" 表示服务器端的网路栈写满了,那不是应该加大 so cket send buffer 吗?跟加大 net_buffer_length 有什么关系?net_buffer_length 加再大,但 sock et send buffer 很小的话,网络栈不还是处于写满状态?

2019-01-28

作者回复

好问题[很好的思考]

是这样的,net_buffer_length 的最大值是 1G,这个值比 socket send buffer大(一般是几M)

比如假设一个业务,他的平均查询结果都是**10M**(当然这个业务有有问题,最终是要通过业务解决)

但是如果我把**net_buffer_length** 改成**10M**,就不会有**"Sending to client"** 的情况。虽然网络栈还是慢慢发的,但是那些没发完的都缓存在**net_buffer**中,对于执行器来说,都是**"**已经写出去了"

2019-01-28



长杰

凸 12

遇到过一个场景,用mysqldump对业务db做逻辑备份保存在客户端,客户端是虚拟机,磁盘很快满了,导致server端出现sending to client状态,更糟糕的是业务db更新频繁,导致undo表空间变大,db服务堵塞,服务端磁盘空间不足。

2019-01-28

作者回复

非常好,正是我要说明的一个场景呢,直接用你的例子放在下篇答疑部分哈2019-01-29



IceGeek17

企9

老师你好,几个问题:

按照文中所述, net_buffer是属于MySQL Server层的,在InnoDB引擎层,会使用buffer pool (以page的形式),也就是一个查询所占用的内存是: net_buffer + buffer pool里相关的page页是不是可以这么理解?

当net_buffer写满,会调用网络接口发出去,net_buffer里的内容是如何发给socket send buffer的,

是一行一行的扔给socket send buffer, 还是把net buffer 里的内容一下子全部扔给 socket send

buffer?

文中说发送成功然后清空net buffer, 这里net buffer是如何清空的, 是等net buffer里的内容全部 发送成功,然后一次性清理,还是发送成功一部分清理一部分?

看了置顶的700问题和回复,几点疑问:

对于一个查询,执行器拿到的所有结果,如果可以一次性放入net_buffer,对于执行器来说是不 是意味着"全都写出去了",也就不会有 sending to client 状态?

只有当查询的结果,不能够全部放入net_buffer,需要等net_buffer里的内容清空后再继续放入 后续的结果,这时候状态才是显示 sending to client?

当查询结果可以全部放入net buffer, 执行器也不管 net buffer是否发送给 socket send buffer, 都认为执行完了?

是不是这么理解?

对buffer pool, 当通过LRU 淘汰数据页的时候,如果此时该页的内容是新的(也就是磁盘上的 内容是老的),是不是需要强制先走一个刷脏页的流程,等脏页刷完了,然后才能淘汰该数据 页?

2019-02-14

作者回复

- 1. "是一行一行的扔给socket send buffer, 还是把net buffer 里的内容一下子全部扔给 socket s end buffer?"
- ---- net buffer写满, 一起发, 然后清空net buffer,组装下一批。好问题
- 2. 跟上一个问题同一个答案:
- 3. "对于一个查询,执行器拿到的所有结果,如果可以一次性放入net_buffer,对于执行器来说是 不是意味着"全都写出去了",也就不会有 sending to client 状态? "----是的
- 4. 是的
- 5. 对,这个就是我们其他文章中介绍的,"带着邻居节点一起刷"的那个阶段。

2019-02-16



Long

ה 5

最近没时间看,今天终于补完了几天的课。

2019-01-28



冰点18

凸 2

InnoDB改进的LRU算法,如果遇到连续两次的全表扫描,会不会就把young区的3/5给覆盖掉了 ? 因为两次扫描时间间隔会超过一秒?

2019-04-01

作者回复

会的

2019-04-05



net_buffer 应该是针对每个请求线程单独分配的,还是共享net_buffer . 我的理解应该是每个线程一块。mysql 可以根据最大请求连接数,能够算出来mysql 使用net_buffer 的总大小。同时如果mysql 占用的内存不大,也将影响到Mysql 能够处理连接连接数的大小。 不知道这种猜测是否准确。 后面那个改进型的LRU 算法真的非常好,就跟JVM 中年轻带 老年代的内存区域划分和淘汰机制一样。在做系统设计的时候可以把这种设计应用一下。

2019-03-30

作者回复

你的理解是对的,每个线程(session)一个 2019-03-31



几近虚年

凸 2

老师,看了课文和留言,有个问题有点懵。

Sending to client 状态,到底是体现了服务端的网络栈 socket receive buffer 写满了(客户端未及时读取),还是 net buffer 满了,还有查询结果没有写入到 net buffer 中?

2019-02-20

作者回复

网络栈 socket receive buffer 写满了

2019-02-20



天使梦泪

r 2

老师好,针对我上次问您的mysql缓存中的数据储存问题,您回答可以一直保存的,具体是怎么实现一直保存的(也不是储存在磁盘上,是使用的内存)?内存重启了之后,缓存不就也丢失了,是怎么做到持久化保存的,老师可以帮忙详细解答下么?

2019-01-29

作者回复

InnoDB 的是buffer pool,是在内存里。

"内存重启了之后,缓存不就也丢失了,是怎么做到持久化保存的,老师可以帮忙详细解答下么 "

没有保存,重启就没有了,要访问的时候需要重新去磁盘读2019-01-29



Sinyo

凸 2

@700的置顶提问

老师你说: "但是如果把 net_buffer_length 改成 10M, 就不会有"Sending to client"的情况。虽然 网络栈还是慢慢发的,但是那些没发完的都缓存在net_buffer中,对于执行器来说,都是"已经 写出去了"。"

假如数据量有1G,而如果要快速减少处于这个状态的线程的话,我们把net_buffer_length 从10 M改成1G,快速减少的那部分操作是不是只有服务端发送到net_buffer的这部分?这样就不会有 "Sending to client"的情况么?

作者回复

还是会显示为"Sending to client",但是语句已经执行完了。

不会占着资源(比如MDL读锁)

2019-01-29



天使梦泪

企 2

老师,我有个问题不明白,mysql从缓存中取数据,缓存里的数据是怎么实现可以保存一段时间的?

2019-01-28

作者回复

"保存一段时间"是啥意思,LRU算法不是按照时间的哈,如果没人来淘汰,是可以一直保存的

2019-01-28



700

企2

老师, 您好。感谢解答。

接上个问题。

Sending to client 是发生在下面哪个阶段的事件呢?

- 1)是 "获取一行,写到 net_buffer 中。"
- 2)还是"直到 net_buffer 写满,调用网络接口发出去。" //即数据从 net_buffer 发到 socket send b uffer?
- 3)还是"将 socket send buffer 的数据发送给 socket receive buffer"

从您的回答"但是如果我把net_buffer_length 改成10M,就不会有"Sending to client" 的情况。",我感觉应该是属于第1)阶段的事件。但感觉这又与您说的"Sending to client 表示的是服务器端的网络栈写满了"相矛盾。

2019-01-28

作者回复

写**net_buffer -- > net_buffer**满了,调用网络接口发 **-->**发不出去 这个是同一个调用链条呀

"哪个阶段"没看懂,是同一个时刻 2019-01-28



如明如月

ഥ 2

之前有特殊功能需要从主要业务库拉取指定范围的数据到另外同一个库的其他数据表的动作(insert into xxxxx select xxx from xxx 这种操作)数据量在万级或者十万级,对于这种操作,和本文讲的应该有些不同吧?能否帮分析一下这种场景的大致情况呢?或者有什么好的建议吗?

2019-01-28

作者回复

嗯,这个不会返回结果到客户端,所以网络上不会有问题

引擎内部的扫描机制是差不多的

唯一不同是这个过程可能对原表有行锁(如果设置的是RR)

万或者十万还好, 是小数据, 可以考虑拿到客户端再写回去, 避免锁的问题

2019-01-28



尘封 <u>6</u> 2

如果一行数据超过了net buffer length的默认值16KB会如何?

2019-01-28

作者回复

满16k就发给socket send buffer

2019-01-28



是我的海

ഥ 1

在线上遇到过一个问题:

- 1.在慢日志中看到一条业务 sql 语句执行时间较长,但是自己在数据库中执行时瞬间返回结果
- ,可能是什么原因?会是由于发送的数据多阻塞造成的么?(net buffer length太小?)
- **2.**慢查询语句到底是如何定义的?处于sending to client 状态,是不是也会统计等待写入 net_buf fer_length 的时间呢?

2019-03-28



进阶的码农

凸 1

如果客户端是在主机上呢

2019-03-01

作者回复

你把他们当作两个单独的行为,只是刚好共同同一个文件系统而已 2019-03-01



Richard

r ኅ

老师好,作为一个java后端开发人员有个疑问,如果对一个大表进行select,如: select * from big table;

用一个List<Object>来接,那么应该是把数据都一次性读入内存了吧,是和上面的全表扫描边读边写的情况不同的吧?也就是我所说的这种操作是可能导致OOM的是吗

2019-02-19

作者回复

嗯,这种情况下是可能导致你的客户端应用占用内存过多的。。

2019-02-19

XXL



请教老师一个问题,

凸 1

之前在开发工程中实际有碰到这样的业务,批量从MySQL中查询大量数据,每次通过限制起始

+limit数量的来分批次查询,后来有同事推荐使用MySQL JDBC中的fetchSize()方法,不做分页通过一次大查询然后客户端流式读取来批量查询数据,这个内部原理是否就是文中所说的使用了mysql_use_result接口读一行处理一行实现的流式?或者也是mysql_store_result方式客户端边缓存边处理?请老师指教

2019-02-14

作者回复

对,这种一般就是用mysql_use_result 各有优劣吧

- 一次性取的好处是,对服务端只全表,只扫描一遍:坏处是可能会出现大事务。
- 一般更常见的做法是,分批取,然后每一批拿到最大的一个id(主键值)下一批查询的时候用 where id > N 这种写法

好问题

2019-02-16



zzz2

凸 1

老师,请问mysql内存命中率和缓存命中率qcache hits是什么关系?

2019-02-13

作者回复

qcache hits说的就是查询缓存命中率吧

一般我们说内存命中率,一般是指buffer pool命中率 2019-02-13



梁中华

凸 1

感觉young 和old 的叫法反了,后面的应该叫young 才好理解。另外文中的old 区也会有类似young 区域的淘汰策略吧

2019-01-30

作者回复

好几个同学这么说,我都方了 这句是官方文档上的

"Accessing a page in the old sublist makes it "young", moving it to the head of the buffer pool" 2019-01-30



Leon

企 1

如果客户端读结果不及时,会堵住 MySQL 的查询过程,但是不会把内存打爆。这个是指客户端的tcp滑动窗口处理没有及时确认,导致server端的网络协议栈没有多余的空间可以发送数据,导致server的处理线程停止从db读取数据发送给client,是这样理解吗

2019-01-30

作者回复

对的

2019-01-30